

Implementatie slimme AI-agent voor IT-support, self- service en intake

Reflectie

Thomas Van Sande
Student Bachelor in Applied Computer Science – Machine Learning

Inhoudsopgave

1. INLEIDING	3
2. INHOUDELIJKE REFLECTIE	4
3. PERSOONLIJKE REFLECTIE	6

1. Inleiding

In dit document wordt een reflectie gemaakt van mijn stage. Eerst behandel ik de inhoudelijke reflectie. Dit wil zeggen dat ik terugkijk naar mijn gerealiseerde oplossing en een analyse opmaak van hoe dit verlopen is. Zo zal ik toelichten welk probleem ik hier mee oplos. Verder kijk ik terug naar welke zaken goed gingen en welke zaken zorgden voor problemen. Ten slotte analyseer ik ook wat in de toekomst best nog kan gebeuren.

In het tweede deel van de reflectie behandel ik de persoonlijke kant. Hierin kijk ik naar hoe ik deze stage op persoonlijk vlak heb ervaren. Ik bespreek hoe ik gegroeid ben, waar ik nog op bots, hoe ik qua gevoel de stage ervaren heb. Ook behandel ik problemen die ik ben tegengekomen en hoe ik die aangepakt heb.

2. Inhoudelijke reflectie

De opdracht die ik moest ontwikkelen was om een AI-agent te ontwikkelen die supportvragen kan beantwoorden en bij een nieuwe behoefte een intake kan opstarten die kan leiden tot een ticketaanmaak. De informatie voor het beantwoorden van de vraag moet komen van bepaalde kennisbronnen.

In mijn implementatie heb ik gekozen voor een Retrieval-Augmented Generation (RAG)-framework. Dit framework laat toe om informatie van bronnen op te slaan in een database en bij een inkomende vraag wordt die database doorzocht om relevante blokjes informatie hieruit te halen. Dit geeft de LLM vervolgens de nodige context om een juist en betekenisvol antwoord te kunnen geven. Wanneer niet genoeg relevante informatie kan gevonden worden, zal een intake met gerichte vragen gebeuren die vervolgens kan leiden tot een TOPdesk-ticket via de API. De toevoeging van een reranker-model in deze implementatie was een van de belangrijkste. Dit model is een extra stap na het ophalen van relevante informatie. Deze filtert die informatie om enkel echt de meest belangrijke informatie over te houden. Dit bleek zeer effectief.

Deze realisatie betekent dat het gehele proces van vraag tot antwoord of ticket volledig wordt geautomatiseerd. Voordien moest een gebruiker op de SharePoint Service Catalog zelfstandig op zoek gaan naar de informatie. Met de vele pagina's daar aanwezig kan dit veel tijd in beslag nemen. Met mijn oplossing hoeft enkel een vraag gesteld te worden en gebeurt alles verder via de agent, zonder dat het antwoord niet gebaseerd is op de inhoud van die SharePoint-pagina's. Ook zal nu dus de gebruiker niet vele hyperlinks moeten openen en is alles gecentraliseerd.

Mijn vooropgestelde doel van waar ik wou eindigen is gelukt. Ik wou een volledig functionele pipeline waar alle vereiste functionaliteiten geïntegreerd zijn. Ik ben ook tevreden met de extra toevoeging van een reranker-model. Dit wordt nog niet in alle projecten toegepast die een RAG-framework gebruiken, ook al heeft dit dus duidelijk een meerwaarde. Ik denk ook dat ik erin geslaagd ben om dit project heel sterk te optimaliseren wat betreft resources. Ik moest dit namelijk uitwerken op mijn eigen laptop (die enkel CPU heeft). Dat maakte dat ik over elk concept veel opzoekwerk moest doen om te begrijpen hoe ik zo weinig mogelijk belasting toevoeg op de pipeline.

Mijn oplossing kan sowieso nog verder geoptimaliseerd worden. Uiteraard kan een zwaardere LLM gebruikt worden die betere antwoorden zal genereren en ook beter de promptinstructies zal opvolgen. Maar daarbuiten is de retrieval ook iets waar verdere optimalisatie zeker nog nodig zal zijn. Op dit moment worden voor de meeste vragen wel goede blokken informatie opgehaald, maar er zijn nog steeds momenten waarop dit niet het geval is. En hoe complexer de vraag, hoe moeilijker het wordt om de juiste informatie te vinden voor het systeem. Een kwalitatief beter embedding model is al een eerste stap hierin. Het is logisch dat een model dat sterker is in informatie omzetten naar semantische representaties, de kans zal verhogen dat vragen met de juiste blokken informatie gelinkt worden.

Daarbovenop is er ook nog de manier waarop je de blokken informatie opsplijt (chunking) om ze in de vector database op te slaan. Er zijn vele opties aanwezig en in de toekomst zullen er ook nog meer chunkingmethodes bijkomen. Ik heb niet de tijd gehad om elke methode uit te proberen en sommige methodes zijn ook te belastend. Het is altijd belangrijk om na te denken over de structuur van de gewenste kennisbronnen en dan goed na te denken hoe deze het best opgedeeld kunnen worden. Dit is ook afhankelijk van wat je met die inhoud moet doen. De SharePoint bronnen bevatten veel informatie dus de splitsing mag niet te groot zijn. Je wil echter niet te veel verschillende informatie in één blok splitsen, die dan veel betekenis verliest wanneer ze wordt omgezet naar een embedding. Dus je wil relatief kleine chunks. Het blijft altijd een beetje een zoektocht naar de meest optimale configuratie.

Die optimale configuratie bepalen hangt ook sterk af van hoe uitvoerig je test. Ik heb zelf ook drie manieren geïmplementeerd van testen. Namelijk via een testset van vragen, een LLM-as-judge, en een feedbacksysteem voor de gebruiker. Dat laat toe om snel verschillende parameters of modellen te testen en te vergelijken waar de verschillen zitten in de kwaliteit van de retrieval of het antwoord.

Ook ontwikkelt de technologie rond AI zich verbijsterend snel. Het is mogelijk dat vele elementen die ik nu toegevoegd heb in mijn oplossing binnen een paar maanden op een veel betere manier gedaan kunnen worden. Het is dus altijd aangeraden om up-to-date te blijven met huidige ontwikkelingen rond AI, want het gaat allemaal heel snel. Wat betreft LLM-modellen raad ik ook aan om te observeren welke Europese alternatieven worden geïntroduceerd. Mistral is bijvoorbeeld aan het opkomen en er zullen ongetwijfeld nog meer volgen. Dit geeft toch een beter gevoel wat betreft privacy en databescherming.

Ik denk niet dat mijn oplossing gebruikt zal worden voor de echte omgeving. Wel is het zo dat de opdrachtgever op dit moment op zoek is naar een productiewaardige oplossing die gelijklopend is met mijn opdracht. Maar een open-source stack op een laptop gaat nooit betrouwbaar genoeg zijn voor een echte productieomgeving. De kans dat de LLM hallucineert of dat de retrieval niet altijd goed gaat, is te groot en voor dit soort projecten moet die kans bijna nul zijn. Antwoorden en opgehaalde informatie moeten vrijwel altijd correct zijn.

Ten slotte is mijn bevinding dat bij dergelijke opdrachten het essentieel zal zijn om menselijke controle in het proces te behouden. In vele productieomgevingen worden volledige agentic workflows ontwikkeld, maar dit wil zeggen dat agents via prompts zelf zullen bepalen of ze tools oproepen en hoe vaak ze dit doen. Dit kan een situatie creëren waarbij het tokengebruik onnodig veel is. En dit leidt tot hoge kosten. Daarom is het belangrijk om een goed inzicht te krijgen in het verwachte tokengebruik voor je applicatie. In mijn project bepaal ik zelf wanneer een bepaalde flow wordt uitgevoerd. Dit wil zeggen dat dit geen onverwachte calls heeft en dat tokengebruik en latency relatief statisch zullen blijven. Ook is de toevoeging van mijn evaluatiemethoden zodanig opgesteld dat dit enkel informatie biedt aan de ontwikkelaar. En dan is het aan de ontwikkelaar zelf om te bepalen hoe hij de informatie wil gebruiken (bijvoorbeeld prompt aanpassen). Op die manier blijft de mens degene die in controle is van de applicatie en wordt de AI enkel en alleen maar gebruikt als hulpmiddel.

3. Persoonlijke reflectie

Op persoonlijk vlak was dit een heel leerrijke ervaring voor mij, maar het is ook een heel belangrijke geweest. Ik bekeek de stage als een ideale overgang om van een schoolsetting over te stappen naar een werkomgeving. Vooraf wist ik dat het zeker niet gemakkelijk zou zijn. Ik wist van mezelf dat ik een goede werker ben en dat 13 weken voltijds werken dus op dat vlak geen probleem ging zijn. Maar mijn grootste struikelblok zijn communicatie en sociale vaardigheden. En ongetwijfeld zou ik in deze stage geconfronteerd worden met deze elementen. Mijn hoop was dan ook vooral om in deze zaken te groeien.

Ik ben blij met de progressie die ik heb gemaakt op het vlak van communicatie. In het begin was ik meer teruggetrokken en probeerde ik zo lang mogelijk uit te stellen om aan te geven dat ik problemen had, omwille van de angst om het contact te durven leggen. Gaandeweg is dit beter verlopen. Ik voelde dat ik me meer comfortabel begon te voelen en dit maakte het voor mij ook gemakkelijker om bepaalde zaken dan aan te kunnen geven. Ik heb vaak ook met collega's in de middag geluncht of een korte wandeling gemaakt. Een voorbeeld van groei op het vlak van communiceren was wanneer ik toegang verloor tot de TOPdesk omgeving. Het durft wel eens te gebeuren dat ik vele uren verspil met zelf dit probleem te willen oplossen omdat ik andere personen niet wil storen. Maar ik heb me gedwongen om gewoon dat contact te leggen en aan te geven dat ik de toegang kwijt ben. Hierdoor had ik vrijwel direct terug toegang tot de omgeving en verloor ik geen onnodige tijd.

Een ander moeilijk aspect is het geven van presentaties. Het eerste jaar in Thomas More ben ik gestart met het geven van presentaties enkel voor de docent, omdat dit zo'n moeilijke opgave was voor mij om te kunnen doen. Doorheen de opleiding heb ik steeds geprobeerd om beter te worden en uiteindelijk dit ook voor een publiek te kunnen doen. Tijdens de stage heb ik een presentatie gegeven voor een 10-tal collega's. Ik wist dat dit stressvol zou zijn, zeker toch de aanloop hiernaartoe. Maar ik heb gewoon besloten dit te doen en heb door persoonlijke ontwikkelingen goed geleerd om hiermee om te gaan. Ik vond dan ook dat ik me relatief kalm heb kunnen houden tijdens de presentatie en dat die presentatie ook goed verlopen is. Dat is ook de feedback die ik ontvangen heb, dus dat is voor mij heel waardevol.

Ook wat betreft planning is progressie gemaakt. Voor zulke grote opdrachten heb ik een beperkte ervaring met hoe dit in te plannen. Op advies van de stagementor heb ik diagrammen gemaakt van flows die steeds uitgebreider worden. Dit gaf me het perfecte template om te starten met de basisflow en dan telkens uit te breiden. De planning heb ik dan ook hierop afgesteld. Het geeft veel meer interne rust wanneer je steeds voelt dat je op schema ligt en dat je altijd progressie maakt zonder dat ik overweldig word door de omvang van het project.

Een van mijn sterktes is dat ik heel goed kan omgaan met stressvolle situaties. Wanneer ik hiermee word geconfronteerd kan ik deze snel relativeren en gericht een plan opmaken om deze op te lossen. Vaak doe ik dit door niet te ver vooruit te kijken. Dit heb ik bijvoorbeeld toegepast met de vraag of ik mee wou gaan naar de hackathon op 19 en 20 mei in Zaventem. Ik weet van mezelf dat ik dit eigenlijk niet zo graag zou willen doen omwille van de sociale prikkels, maar ook onzekerheden die zich zullen voordoen. Maar ik kan zelf snel beseffen dat ik rustig moet blijven en goed hierover moet nadenken. Zo kan ik concluderen dat die hackathon een leerrijke ervaring kan zijn voor mij en dat niemand me het kwalijk zou nemen mocht ik problemen hebben tijdens het ontwikkelen. Een paar jaar geleden zou ik dit bijvoorbeeld nooit gedurfd hebben en ik ben tevreden hoe ik ook hier concreet progressie op heb gemaakt.

Op het vlak van gedisciplineerd werken en gefocust zijn tijdens de werkuren heb ik weinig negatiefs te zeggen. Ik denk dat ik hier echt wel sterk in ben. Het is leuk dat dit ook in de feedbackmomenten is besproken.

Om te concluderen kan ik wel stellen dat ik gegroeid ben tijdens deze stage. Ik wist dat er vele momenten gingen zijn die moeilijk gingen zijn en dat ik hiermee wou leren omgaan. En ik kan wel zeggen dat dit ook gebeurd is. De presentatie geven voor een relatief groot publiek en die tot een goed einde brengen is toch iets waar ik met trots op terugkijk.

Het was een leuke ervaring om me 13 weken te kunnen richten op 1 project waarin ik eigenlijk volledige controle had over hoe ik het ging aanpakken. Ik ben ook heel tevreden met hoe dit uitgedraaid is. Ik heb leuke collega's ontmoet en heb leuke gesprekken met deze gehad. Het is moeilijk om in te schatten hoe werken zal uitdraaien op persoonlijk vlak. Deze stage heeft me veel zelfvertrouwen gegeven en me doen realiseren dat dit een omgeving is waar ik me comfortabel in voel en waar ik tot zelfontplooiing kan komen. Je kan dus wel stellen dat deze stage de perfecte brug is gebleken om me volledig klaar te stomen om als afstuderende student klaar te zijn voor de arbeidsmarkt.